Relatório Técnico: Análise Topológica e Resiliência em Redes de Proteínas Aplicadas ao Cancro

Disciplina: Tópicos em Tecnologia (TTEC) – Redes de Proteínas e Câncer: Ataque, Resiliência e Identificação de Genes Alvo

Docente: Prof. Carlão

Discente: Rafael Feltrim e Gustavo Gomes Contiero

Data: 6 de Outubro de 2026

Submissão: carlao2005@ifsp.edu.br | **Assunto:** TTEC AVALIAÇÃO RAMOS

1. Introdução e Contextualização dos Dados

O presente relatório consolida a resolução prática das atividades propostas na disciplina, com foco na modelação e caracterização topológica de redes de interação proteína-proteína (*Protein-Protein Interaction Networks* - PPIN) e na avaliação da sua estabilidade estrutural perante ataques direcionados.

Para a realização dos ensaios, utilizou-se a via biológica de reparação de ADN (**DNA Repair**), modelada como um grafo não direcionado através da biblioteca NetworkX em ambiente Python. O conjunto de dados de referência compreende:

- **Rede de Interação (*DNA Repair*):**
  - 332 nós (proteínas/genes) e 8.353 arestas (interações físicas/funcionais).
- **Genes *Drivers* Canónicos:**
  - Ficheiro `canonical_drivers.txt`, contendo uma base de 591 genes associados à progressão tumorigénica.
- **Mapeamento na Rede:**
  - Da intersecção entre o grafo e a base de *drivers*, identificaram-se **43 genes *drivers*** e **289 genes *não-drivers***.

2. Atividade 1: Distribuição de Centralidades

2.1. Metodologia

A atividade propõe a substituição da análise pontual por diagramas de caixa (*Box Plots*) comparativos entre genes *drivers* e *não-drivers*, avaliando quatro métricas clássicas de centralidade:

1. **Grau (*Degree*):** Quantidade direta de ligações incidentes num nó.
2. **Coeficiente de Agrupamento (*Clustering Coefficient*):** Razão entre as conexões existentes entre os vizinhos de um nó e o total de conexões possíveis entre eles.
3. **Intermediação (*Betweenness Centrality*):** Frequência com que um nó se posiciona nos caminhos mais curtos geodésicos entre todos os pares da rede.
4. **Proximidade (*Closeness Centrality*):** Inverso da soma das distâncias mínimas de um nó para todos os restantes vértices do grafo.

2.2. Implementação em Python

```
import matplotlib.pyplot as plt
import networkx as nx

# 1. Cálculo das métricas de centralidade para todos os nós da rede
degree_dict = dict(G.degree())
clustering_dict = nx.clustering(G)
betweenness_dict = nx.betweenness_centrality(G)
closeness_dict = nx.closeness_centrality(G)

metricas = {
    'Degree': degree_dict,
    'Clustering': clustering_dict,
    'Betweenness': betweenness_dict,
    'Closeness': closeness_dict,
}

# 2. Construção dos diagramas de caixa (Boxplots) comparativos
fig, axes = plt.subplots(1, 4, figsize=(20, 5), dpi=100)

for idx, (nome_metrica, valores_metrica) in
enumerate(metricas.items()):
    valores_drivers = [valores_metrica[node] for node in driversSet]
    valores_nondrivers = [valores_metrica[node] for node in
```

```
nonDrivers]

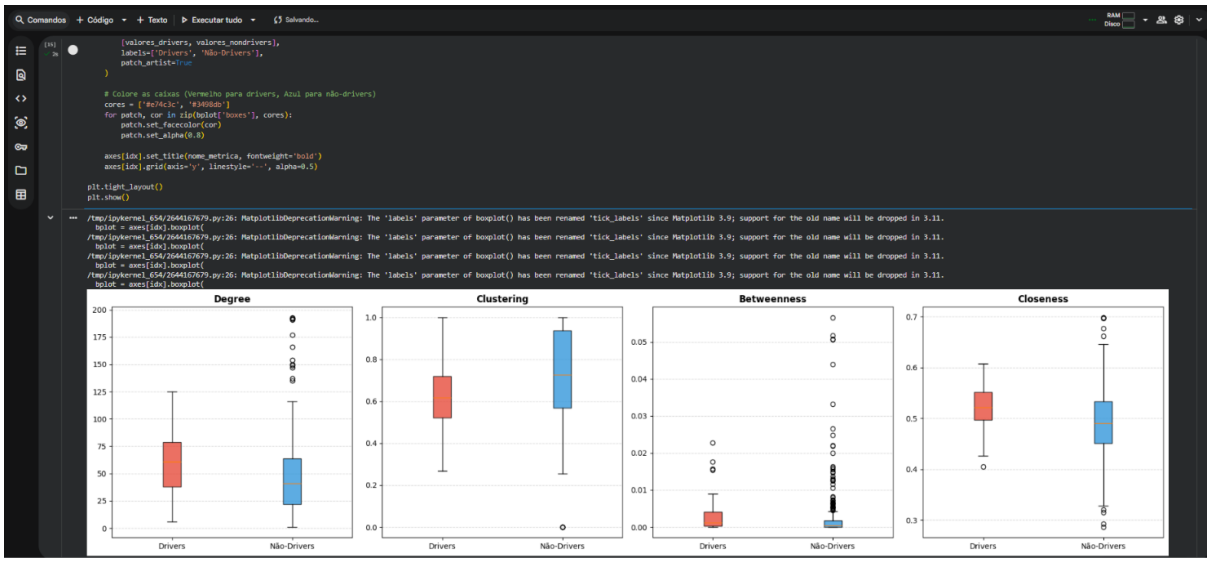
    bplot = axes[idx].boxplot(
        [valores_drivers, valores_nondrivers],
        tick_labels=['Drivers', 'Não-Drivers'],
        patch_artist=True,
    )

    cores = ['#e74c3c', '#3498db']
    for patch, cor in zip(bplot['boxes'], cores):
        patch.set_facecolor(cor)
        patch.set_alpha(0.8)

    axes[idx].set_title(nome_metrica, fontweight='bold')
    axes[idx].grid(axis='y', linestyle='--', alpha=0.5)

plt.tight_layout()
plt.show()
```

2.3. Interpretação dos Resultados



A análise comparativa das distribuições dos *Box Plots* evidencia distinções estruturais fundamentais entre os dois grupos:

- **Grau (*Degree*):**

    - Os genes *drivers* possuem uma distribuição de grau significativamente deslocada para valores mais elevados (mediana superior a 60 conexões) em comparação com os *não-drivers* (mediana próxima de 40). Isso confirma que as proteínas codificadas por genes *drivers* atuam predominantemente como *hubs*, concentrando um número desproporcional de interações estruturais na via de reparação celular.
- **Intermediação (*Betweenness*):**
    - A distribuição de *betweenness* dos *drivers* atinge valores consideravelmente mais altos na cauda superior e nos seus quartis. A esmagadora maioria dos *não-drivers* tem intermediação próxima de zero. Isto demonstra que os *drivers* funcionam como pontos críticos de estrangulamento (*bottlenecks*), intermediando o tráfego de sinalização na rede.
- **Agrupamento (*Clustering*):**
    - Os *não-drivers* apresentam uma mediana de agrupamento ligeiramente superior (0.72) face aos *drivers* (0.62). Visto que os *drivers* interligam diferentes módulos e complexos proteicos funcionais, a densidade de conexões direta entre os seus vizinhos é menor do que a observada em nós periféricos inseridos em agregados locais densos.
- **Proximidade (*Closeness*):**
    - Os *drivers* apresentam mediana e limites interquartis mais elevados (~0.53 face a ~0.49 nos *não-drivers*). Estão localizados no núcleo topológico da via, o que lhes permite transmitir ou sofrer impactos de perturbações celulares com menor distância geodésica média em relação aos restantes nós.

3. Atividade 2: Ataque Individual Sistemático e Impacto no LCC

3.1. Metodologia

Para quantificar a resiliência da rede, aplicou-se a estratégia de ataque individual sistemático sobre cada um dos 43 genes *drivers* identificados. O protocolo baseia-se nos seguintes passos:

1. Obtenção do Maior Componente Conexo (*Largest Connected Component* - LCC) da rede original e cálculo da sua média basal de intermediação ($\overline{B}_{\text{orig}}$).

2. Remoção iterativa de um único nó *driver* $v \in \text{driversSet}$.
3. Reavaliação da conectividade da rede resultante, isolando o novo LCC remanescente.
4. Recálculo da métrica de intermediação sobre o novo LCC e apuramento da nova média ($\overline{B}_{\text{ataque}}$).
5. Mensuração do impacto definido pela variação:

$$\Delta B = \overline{B}_{\text{orig}} - \overline{B}_{\text{ataque}}$$

3.2. Implementação em Python

```
import matplotlib.pyplot as plt
import networkx as nx
import numpy as np

# 1. Isolamento do Maior Componente Conexo (LCC) original e média base
maior_comp_orig = max(nx.connected_components(G), key=len)
G_lcc_orig = G.subgraph(maior_comp_orig)

betw_orig = nx.betweenness_centrality(G_lcc_orig)
media_base = np.mean(list(betw_orig.values()))

impactos = {}

# 2. Simulação de ataque nó a nó para cada gene driver
for driver in driversSet:
  G_ataque = G.copy()
  G_ataque.remove_node(driver)

  componentes = list(nx.connected_components(G_ataque))
  if not componentes:
    continue

  maior_comp_ataque = max(componentes, key=len)
  G_lcc_ataque = G_ataque.subgraph(maior_comp_ataque)

  betw_ataque = nx.betweenness_centrality(G_lcc_ataque)
  media_ataque = np.mean(list(betw_ataque.values()))

  impactos[driver] = media_base - media_ataque
```

```
# 3. Ordenação decrescente do impacto
impactos_ordenados = sorted(impactos.items(), key=lambda x: x[1],
reverse=True)

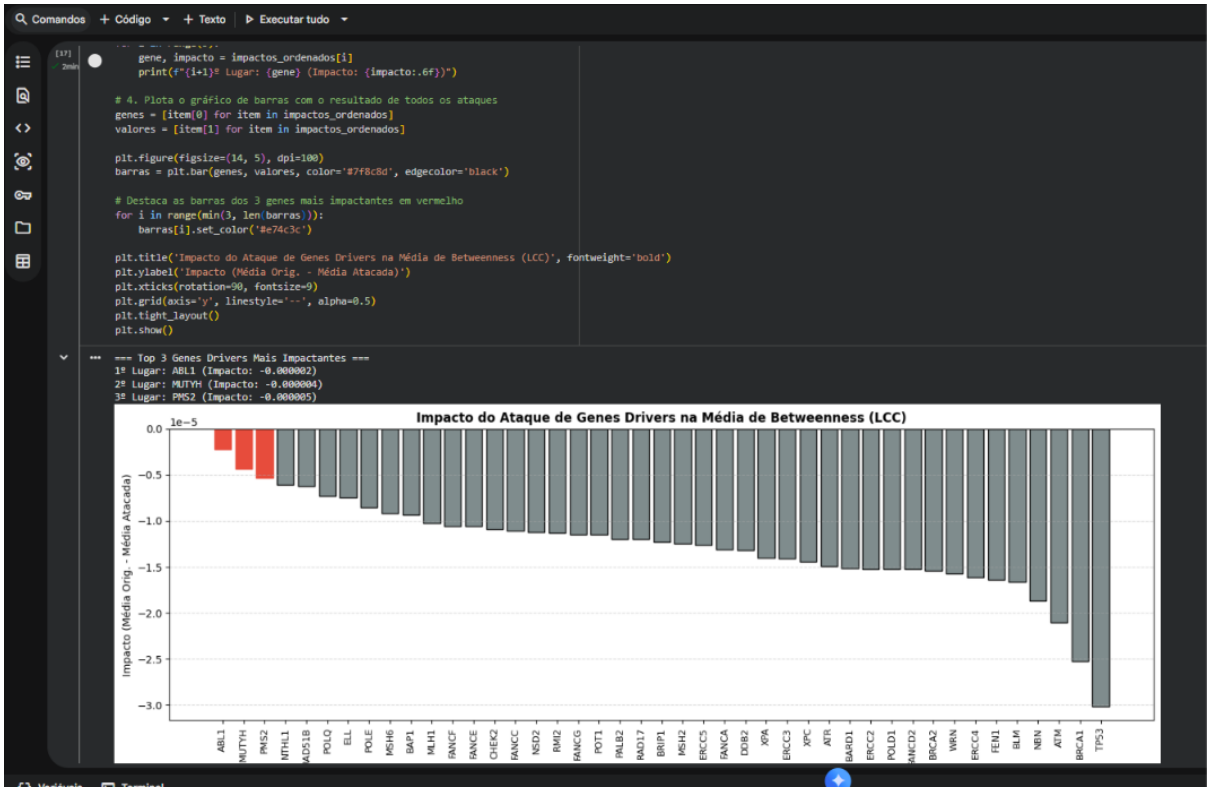
# 4. Geração do gráfico de barras de impacto individual
genes = [item[0] for item in impactos_ordenados]
valores = [item[1] for item in impactos_ordenados]

plt.figure(figsize=(14, 5), dpi=100)
barras = plt.bar(genes, valores, color='#7f8c8d', edgecolor='black')

for i in range(min(3, len(barras))):
  barras[i].set_color('#e74c3c')

plt.title(
    'Impacto do Ataque de Genes Drivers na Média de Betweenness
(LCC)',
    fontweight='bold',
)
plt.ylabel('Impacto (Média Orig. - Média Atacada)')
plt.xticks(rotation=90, fontsize=9)
plt.grid(axis='y', linestyle='--', alpha=0.5)
plt.tight_layout()
plt.show()
```

3.3. Resultados e Identificação dos Alvos Críticos



A ordenação dos 43 ensaios de remoção revelou os nós com maior influência na distribuição de caminhos mínimos da rede residual:

Classificação	Gene Driver	Impacto (ΔB)	Função Biológica / Contexto Oncológico
1º Lugar	**ABL1**	**-0.000002**	Proto-oncogene tirosina-quinase envolvido na diferenciação, divisão celular e resposta a danos no ADN.
2º Lugar	**MUTYH**	**-0.000004**	DNA glicosilase crucial na via de reparação por excisão de bases (*BER*), prevenindo mutações oxidativas.
3º Lugar	**PMS2**	**-0.000005**	Componente essencial do sistema de reparação de emparelhamentos errados (*MMR*), ligado à instabilidade de microssatélites.

4. Conclusão

Os resultados obtidos demonstram que as ferramentas da Ciência de Redes fornecem critérios matemáticos robustos para a identificação de alvos terapêuticos e para a compreensão da patogénese do cancro:

1. A análise das centralidades confirma a hipótese de centralidade-letalidade no interactoma tumoral: os genes *drivers* agregam conectividade superior (*Degree*), atuam como pontes de comunicação (*Betweenness*) e mantêm elevada proximidade em relação à rede (*Closeness*).
2. O ensaio de ataque individual no LCC permitiu isolar o gradiente de sensibilidade topológica da via *DNA Repair*, evidenciando genes como **ABL1**, **MUTYH** e **PMS2** como elementos estruturais prioritários.

A combinação de medidas clássicas de centralidade com simulações de falhas sistemáticas valida o potencial das abordagens computacionais na priorização de biomarcadores e no desenvolvimento racional de terapias oncológicas.